

Практикум по формальным языкам

Задача №14

Дано слово W , найти подслово слова W максимальной длины, такое, что оно является подсловом некоторого слова из языка L .

Решение:

Переберем все подслова слова W , пусть мы зафиксировали какое-то подслово U , проверим, является ли U подсловом некоторого слова в языке L . Выберем $U_{\max} = U$ с максимальной длиной из всех тех U , которые являются подсловом некоторого слова в языке L . Длина U_{\max} и будет ответом на нашу задачу.

Итак, мы зафиксировали U , нужно проверить, является ли оно подсловом некоторого слова из языка L . Будем решать задачу с помощью индукции по построению. Для каждого языка будем хранить некоторые характеристики и вычислять их значения для языка $L1.L2$, $L1+L2$, $(L1)^*$, зная значения этих характеристик для $L1$ и $L2$.

Опишем характеристики языка L :

1. `containsSubstring[i][j] == true` \Leftrightarrow подслово слова U длины j , начинающееся в i -ой позиции, содержится в языке L .
2. `containsEpsilon == true` \Leftrightarrow пустое слово принадлежит нашему языку L .
3. `containsWordAsSubstring == true` \Leftrightarrow слово U содержится в качестве подслова какого-либо слова из языка L (Главный параметр, который и является ответом на нашу подзадачу)
4. `containsSuffixEqualsToPrefix[i] == true` \Leftrightarrow в языке L есть слово V , такое, что суффикс (длины i) S слова V равен префиксу длины i слова U .
5. `containsPrefixEqualsToSuffix[i] == true` \Leftrightarrow в языке L есть слово V , такое, что префикс (длины i) P слова V равен суффиксу длины i слова U .

(Все эти характеристики еще раз описаны в коде в виде комментариев)

Опишем базу, то есть характеристики для языка, состоящего из одного слова длины ≤ 1 , то есть это слово равно либо какой-то букве x , либо пустому слову. Изначально все поля равны `false`.

1. `containsSubstring[i][1] := true`, если `U[i] == x`.
2. `containsEpsilon := true`, если `x` – пустое слово.
3. `containsWordAsSubstring := true`, если `U == x`.
4. `containsSuffixEqualsToPrefix[1] := true`, если `U[0] == x`.
5. `containsPrefixEqualsToSuffix[1] := true`, если `U[U.length - 1] == x`.

Опишем переходы, то есть сейчас мы знаем характеристики L_1 и L_2 и вычисляем характеристики языка $(L_1 + L_2)$, $(L_1 \cdot L_2)$, $(L_1)^*$:

$(L_1 + L_2)$:

Здесь все достаточно тривиально, если какая-либо из характеристик была равна `true` либо в языке L_1 , либо в языке L_2 , либо и там и там, то в языке $(L_1 + L_2)$ эта характеристика будет равна `true`, а иначе `false`.

$(L_1 \cdot L_2)$:

(Комментарии и пояснения для этих переходов так же присутствуют в коде)

1. `L.containsSubstring[i][j] := true`, если
 - Либо найдутся такие `prefixLength` и `suffixLength`, что:
 - `prefixLength > 0` и
 - `suffixLength > 0` и
 - `prefixLength + suffixLength == j` и
 - `L1.containsSubstring[i][prefixLength] == true` и
 - `L2.containsSubstring[i + prefixLength][suffixLength] == true`
 - Либо `L1.containsEpsilon == true` и `L2.containsSubstring[i][j] == true`
 - Либо `L2.containsEpsilon == true` и `L1.containsSubstring[i][j] == true`
2. `L.containsEpsilon := true`, если
 - `L1.containsEpsilon == true` и
 - `L2.containsEpsilon == true`
3. `L.containsWordAsSubstring := true`, если
 - Либо `L1.containsWordAsSubstring == true`
 - Либо `L2.containsWordAsSubstring == true`
 - Либо найдется такое число `prefixLength > 0`, что
 - `L1.containsSuffixEqualsToPrefix[prefixLength] == true` и
 - `L2.containsPrefixEqualsToSuffix[U.length - prefixLength] == true`

4. `L.containsSuffixEqualsToPrefix[i] := true`, если
 - Либо `L2.containsSuffixEqualsToPrefix[i] == true`
 - Либо `L1.containsSuffixEqualsToPrefix[i] == true` и `L2.containsEpsilon == true`
 - Либо найдется такое число `subPrefixLength > 0`, что `L1.containsSuffixEqualsToPrefix[subPrefixLength] == true` и `L2.containsSubstring[subPrefixLength][i - subPrefixLength] == true`
5. `L.containsPrefixEqualsToSuffix[i] := true`, если
 - Либо `L1.containsPrefixEqualsToSuffix[i] == true`
 - Либо `L2.containsPrefixEqualsToSuffix[i] == true` и `L1.containsEpsilon == true`
 - Либо найдется такое число `subSuffixLength > 0`, что `L2.containsPrefixEqualsToSuffix[subSuffixLength] == true` и `L1.containsSubstring[U.length - i][i - subSuffixLength] == true`

$(L1)^*$:

$$L^* == L^0 + L^1 + L^2 + \dots + L^n + L^{n+1} + \dots$$

Будем честно вычислять значения L^* для каждого шага. То есть, сначала вычислим L^0 , потом $L^0 + L^1$, и так далее.

Понятно, что нам достаточно посчитать только $2 \cdot U.length$ шагов, так как уже на шаге с номером $U.length$ у нас перестанут появляться новые префиксы слова U , так как все новые слова будут длины, большей, чем длина слова U , по той же причине у нас не будут появляться в языке новые подслова слова U , а также, заметим, что, если на шаге с номером N , большим, чем $2 \cdot U.length$ у нас появилось слово в языке с суффиксом, равным какому-либо префиксу слова U , то такое слово уже было в языке на шаге $N/2$, так как $L^N = L^{N/2} \cdot L^{N/2}$. Следовательно, значения характеристик для языка $(L1)^*$ мы будем вычислять, используя операции сложения и умножения, которые мы уже определили.

Таким образом, мы умеем вычислять значения для всех операций, а значит мы можем вычислить для языка, заданного исходным регулярным выражением, значение параметра `containsWordAsSubstring`, который и будет давать нам ответ на нашу подзадачу.